Cours de système

Qu'est-ce qu'un système d'exploitation ?
Introduction à Linux

(cours original de Sébastien Paumier
Sebastien.paumier@u-pem.fr)

Organisation du cours

- 12 cours
- 11 TP
- 1 tp noté
- 1 partiel (Support de cours autorisé)

Le niveau de C est simple !!! C'est surtout la rigueur qui compte (tests, commentaires, bonne compréhension des mécanismes)

Bien faire (et refaire) les TP

Objectifs du cours

- savoir ce qu'est un système d'exploitation (OS)
- connaître les grandes questions à se poser pour en concevoir un
- connaître le modèle de Linux
- savoir programmer des applications système
- Comprendre et anticiper les réactions du système

Ressources

- "Systèmes d'exploitation", d'Andrew Tanenbaum
- poly du cours de système de D. Revuz:
  - http://igm.univ-mlv.fr/~dr
- exemples du cours et code du premier noyau:
  - http://igm.univ-mlv.fr/~cherrier/systeme/

Qu'est-ce qu'un OS ?

- interface entre les applications et le matériel physique

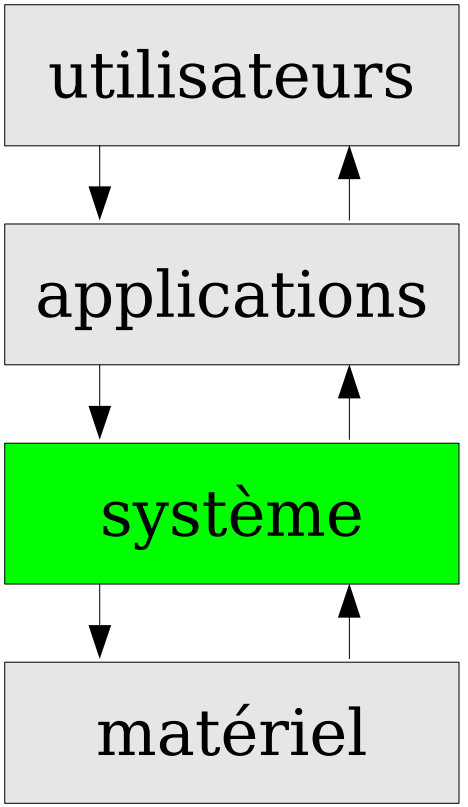

Missions

- accéder au matériel de façon transparente
  - un programme n'a pas à savoir s'il écrit sur un disque ext3 ou une clé USB fat32
  - La souris en blutooth, usb, ps2,etc
- gérer les ressources (accès physiques, mémoire, CPU)
  - optimiser l'usage de la machine (taux d'occupation du CPU, minimisation des mouvements des têtes de lecture des disques, minimiser le swap, gestion de l'énergie sur les systèmes portables, etc)

Missions

- veiller à la sécurité des applications et des données
- fournir une qualité de service
  - éviter les famines, garantir un accès prioritaire à root, temps de réponse sur un OS temps réel, etc
- être robuste
  - éviter de planter !
  - tolérance à l'erreur (disques défectueux, reboot sauvage, bugs applis, etc)

Missions

- Virtualiser la machine
  - Manipulation de concepts plutôt que la réalité (C:/ eth0 ? Clavier, écran, souris ?)
- Multiplicité, unicité
  - Capable de simuler des ressources inexistantes : mémoire, cartes réseau, écrans, machine
  - Capable d'agréger des ressources multiples en une (supports, trunk de cartes réseau, volume (partitions))

Les types de système

- mono vs multi-utilisateurs
  - un OS de téléphone peut être mono-utilisateur
- mono vs multi-tâches
  - DOS était monotâche
- mono vs multi-processeurs
- temps réel: garantit un délai maximal d'exécution quelles que soient les conditions (≠ best effort)

Le multi-utilisateurs

- suppose de pouvoir protéger les données de chacun sur les supports de stockage
- nécessite la notion de droits d'accès
- protège les utilisateurs entre eux
- protège le système:
  - impossible de détruire le système en supprimant par accident une DLL :)
  - Protection contre les programmes malicieux

Le multi-tâches

- suppose de pouvoir protéger les processus les uns des autres
- nécessite la notion de protection de la mémoire
- rendu possible par le mode **protégé** et la mémoire virtuelle paginée du processeur
  - seul le noyau peut accéder à tout
  - les processus ne peuvent physiquement pas sortir de leurs pages mémoire

Le noyau

- espace mémoire protégé+ensemble de programmes qui forment la base minimale de l'OS
- tout ce qui n'est pas un appel système fonctionnera dans l'espace utilisateur
- exemple de choix de conception: l'interface graphique
  - dans le *système* sous Windows
  - programme *utilisateur* (serveur X) sous Linux

Types de noyau

- monolithique: tout est dans le noyau (système de fichiers, pilotes, etc)
  - Linux, FreeBSD
- micro-noyau: seulement le strict minimum (ordonnanceur+mémoire virtuelle)
  - Minix, Mac OS X
- hybride (Windows NT)
- exo-noyau: rien n'est protégé

Pourquoi étudier Linux ?

cf. Halloween Documents

- logiciel libre (ouvert et gratuit)
- très portable (PC, smartphones, embarqué, top500 etc)
- interface simple et élégante (les appels systèmes)
- met en œuvre beaucoup de notions intéressantes: *processus, droits d'accès, mémoire virtuelle, journalisation, temps réel, modules dynamiques, etc*
- formidable mutualisation d'expertise

Primitives systèmes

- Accès aux fonctionnalités du système
- Atomiques
- Décrites dans le chapitre 2 du man
- Retour à tester, toujours..
- Les bibliothèques habituelles se servent des primitives pour rendre leurs services (stdio.h, etc)
- Attention aux différences (open et fopen, printf ou write sur 1 ou 2,...)

Primitives, User et Kernel land

- Les primitives (ou appels systèmes) = API du système

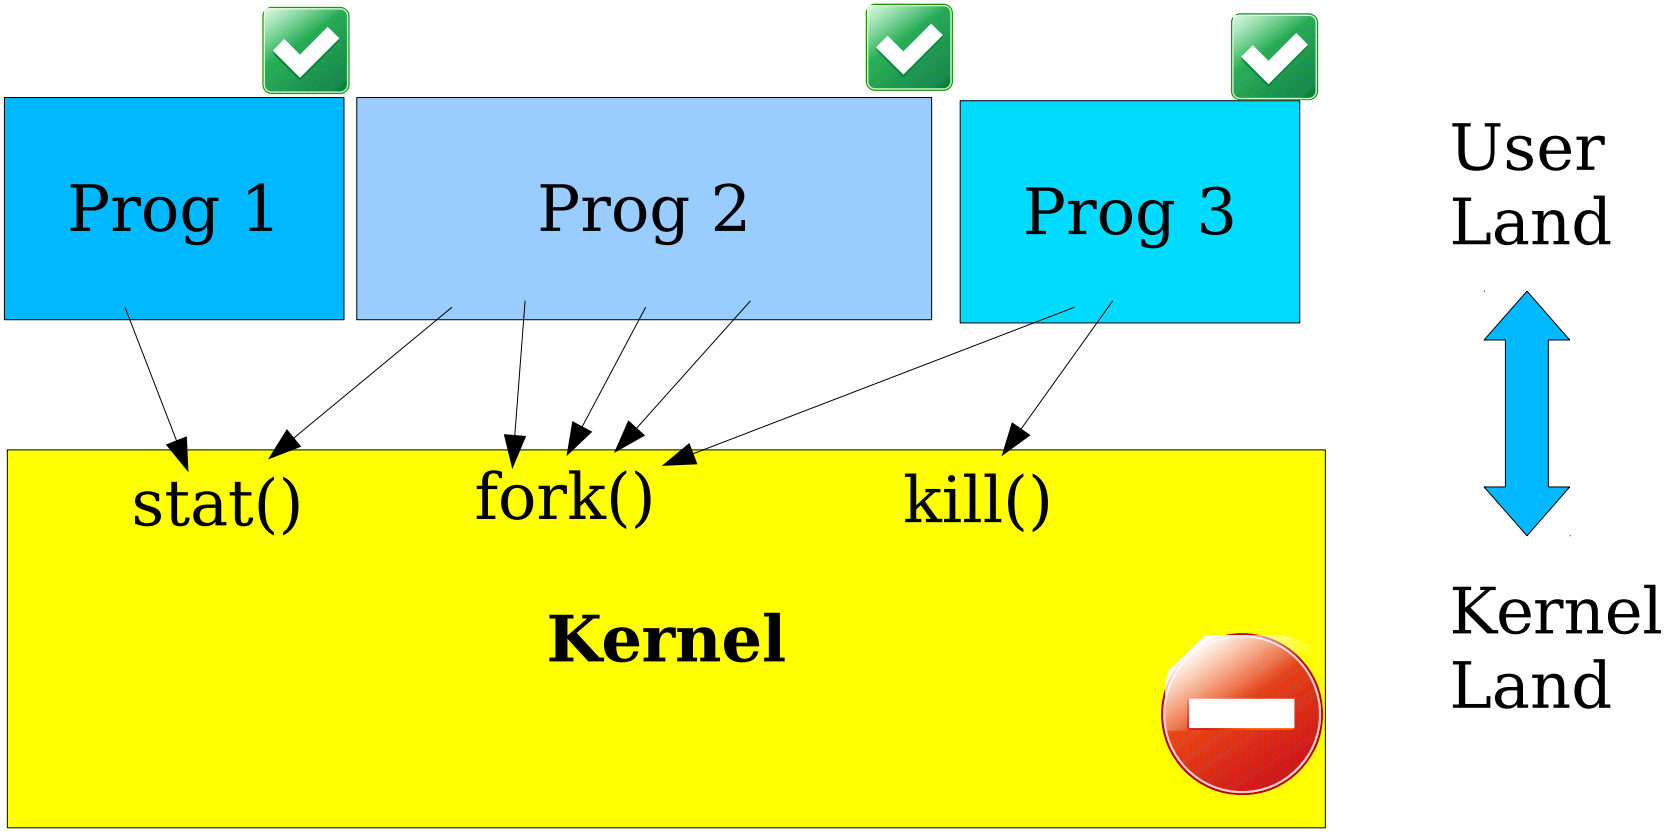

Un peu d'histoire

- 1969: UNIX (Thompson et Ritchie)
- 1987: Minix (Tanenbaum)
- 1991: premier noyau Linux (Torvalds)
- 1994: v1.0 qui donne le premier système GNU/Linux
- depuis, de nombreuses distributions:
  - Debian, Ubuntu, Fedora, SuSE, Red Hat, Mandriva, Slackware, ArchLinux, Gentoo, etc

Un peu d'histoire

- 1950-1975 mainframe, principalement entreprises et grandes structures
- 1975 micro informatique : geek, fortunés ou bricoleurs
- 1981 IBM PC : professionalisation, bureautique.
- ~1990 et + réseau, Internet

Architecture Linux

- noyau monolithique qui gère le matériel, la mémoire, l'ordonnancement des tâches
- séparation en couches (noyau, libs, applications)
- séparation en deux espaces distincts:
  - espace utilisateur (user land)
  - espace noyau (kernel land)
- basée sur un contrôle matériel: le mode protégé du processeur

Mode protégé

- Apparait dès 1982 sur PC (utilisé par Windows à partir de 1992, réllement sur NT)
- Niveaux de privilège (**Ring 0** (dit noyau ou superviseur) à **3** (utilisateur))
- Commutation de contexte
- OS sérieux : Lie les privilèges logiciels à ceux du processeur pour implémenter de la sécurité

Un modèle en couches

- la portabilité est assurée par les couches basses
- possible grâce un langage puissant inventé pour écrire UNIX: le C
- un binaire n'est pas portable, mais il suffit de recompiler une application pour la porter sur un OS compatible
- pas besoin de toucher au code!
- concept ancêtre de l'idée de machine virtuelle, de l'abstraction

Un modèle en couches

- du très bon génie logiciel, car on a des interfaces propres qui permettent de faire abstraction des couches plus basses
- polymorphisme qui facilite la portabilité et l'extensibilité:
  - pour un nouveau processeur, il suffit de changer les codes assembleur bas niveau
  - pour un nouveau système de fichier, il suffit d'implémenter les variantes de **`read`**, **`write`**, **`open`**...

`fs/`

Un modèle en couches

- on obtient des codes plus sûrs, car pour court-circuiter une couche, il faudrait la maîtriser parfaitement
- exemple de bug dû à un mélange entre la couche système et la libc:

```
int main(int argc,char* argv[]) {
    if (argc!=2) return 1;
    int fd=open(argv[1],O_CREAT|O_TRUNC|O_WRONLY,0700);
    FILE* f=fdopen(fd,"w");
    close(fd);
    fprintf(f,"Oooops\n");
    fclose(f);
    return 0;
}
```

bug_FILE.cpp

Modes réel et protégé

- mode réel (par défaut au boot):
  - on peut exécuter n'importe quelle instruction
  - accès total à la mémoire physique
- mode protégé basé sur un contrôle matériel (utilisé dans les OS modernes):
  - protection de la mémoire, ce qui permet la mémoire virtuelle et la pagination
  - commutation de contexte
  - 4 niveaux de privilèges

`boot/boot.s`

Protection de la mémoire

- idée: interdire à un programme d'accéder à de la mémoire qui ne lui appartient pas, s'il n'a pas le bon niveau de privilège
- en mode protégé, tous les accès mémoire sont contrôlés par le processeur par rapport à une zone autorisée
- en cas de violation, Linux tue le programme fautif avec un signal SIGSEGV: *segmentation fault*

`kernel/traps.c`

Commutation de contexte

- changement de contexte:
  - sauver l'état du processus courant (valeurs des registres)
  - restaurer l'état d'un autre processus P
  - reprendre l'exécution de P où elle s'était arrêtée
- permet de donner l'illusion du multi-tâches
- opération critique si trop lente ou trop fréquente

kernel/sched.c
include/linux/sched.h

Bascule noyau/utilisateur

- quand un processus utilisateur doit accéder au système physique, pour des raisons de protection, il doit demander au noyau de le faire pour lui
- d'où l'obligation de changer de contexte en copiant des choses entre *user land* et *kernel land*
- très coûteux, donc on préfère bufferiser autant que possible
- exemple: copie d'un fichier

Bascule noyau/utilisateur

- version basique, utilisant la bufferisation par défaut de la libc:

```
int main(int argc,char* argv[]) {
int c;
while ((c=fgetc(stdin))!=EOF) {
    fputc(c,stdout);
}
return 0;
}
```

```
$>man gcc | time ./io_buf > err
0.01user 0.00system 0:00.57elapsed 2%CPU (0avgtext+0avgdata 0maxresident)k
0inputs+1280outputs (0major+234minor)pagefaults 0swaps
```

Bascule noyau/utilisateur

- version non bufferisée, qui coûte très cher:

```
int main(int argc,char* argv[]) {
setvbuf(stdin,NULL,_IONBF,0);
setvbuf(stdout,NULL,_IONBF,0);
int c;
while ((c=fgetc(stdin))!=EOF) {
    fputc(c,stdout);
}
return 0;
}
```

```
$>man gcc | time ./io_buf > err
0.01user 0.00system 0:00.57elapsed 2%CPU (0avgtext+0avgdata 0maxresident)k
0inputs+1280outputs (0major+234minor)pagefaults 0swaps

$>man gcc | time ./io_unbuf > err
0.34user 1.62system 0:02.09elapsed 93%CPU (0avgtext+0avgdata 0maxresident)k
0inputs+1280outputs (0major+228minor)pagefaults 0swaps
```

Mode noyau/utilisateur

- grâce au mode *protégé,* les programmes utilisateur n'ont physiquement pas accès à l'espace du noyau
- mais en mode *noyau,* on a **tous** les droits !
- le code du noyau étant critique, on met un maximum de choses en dehors
  - exemple: on peut redémarrer un serveur graphique planté sans devoir rebooter

Problème de maintenance

- si on ne peut pas toucher au noyau, on doit le changer ou le recompiler, puis rebooter à chaque mise à jour de n'importe quel morceau!
  - il fût un temps où il fallait recompiler à chaque update d'un driver...
- pour simplifier cela, introduction de codes noyau chargeables dynamiquement: les *modules*

Problème de maintenance

- même philosophie avec les bibliothèques partagées et l'édition de liens dynamiques
- on peut changer un morceau de code sans devoir tout réinstaller ou recompiler, et bien souvent, sans rebooter
  - propriété vitale pour certains systèmes critiques (banques, hopitaux, etc)

Les appels système

- interface simple et élégante pour communiquer de façon homogène
- les diamants:

```
ssize_t read(int fd,void* buf,size_t n);

ssize_t write(int fd,const void* buf,size_t n);
```

- lire ou écrire des octets vers on ne sait pas quoi (et on ne veut surtout pas savoir!):
  - fichier ordinaire, fichier spécial, terminal, socket, tube, périphérique, etc

Les appels système

- peuvent (presque tous) être appelés comme des fonctions
- peuvent être invoqués par **`syscall`**, en utilisant les constantes définies dans **`sys/syscall.h`** de la forme **`SYS_read`**
- attention: certains appels sont wrappés par la libc
  - ne pas mélanger les appels wrappés et les appels directs avec **`syscall`** !

Bug

- un processus qui a le même pid que son père ?

```
int main(void) {
    getpid();
    int i=syscall(SYS_fork);
    if (0==i)
        /* Big problem: the son prints the same value
         * for getpid() and getppid() */
        printf("__son : %d   father : %d__\n", getpid(), getppid());
    else
        printf("<<father : %d   son : %d>>\n", getpid(), i);
    return 0;
}
```

Violation du modèle en couches

- explication dans la page man de **`getpid`**:

```
NOTES

Depuis la glibc version 2.3.4, la fonction enveloppe de la  glibc  pour
getpid() faisait un cache des PID, de façon à éviter des appels système
supplémentaires quand un processus appelle getpid() de  façon  répétée.
Normalement,  ce  cache n'est pas visible, mais son fonctionnement cor-
rect repose sur la gestion du cache dans les fonctions enveloppes  pour
fork(2),  vfork(2)  et  clone(2) :  si  une  application  se  passe des
enveloppes de la glibc pour ces appels système en appelant  syscall(2),
alors  un  appel  à  getpid()  dans le fils renverra la mauvaise valeur
(pour être précis : il renverra le PID du  processus  père).  Consultez
également clone(2) pour une discussion sur un cas ou getpid() peut ren-
voyer une mauvaise valeur quand clone(2) est  appelé  via  la  fonction
enveloppe de la glibc.
```

- toujours lire les docs en entier!!!

Un outil ouvert

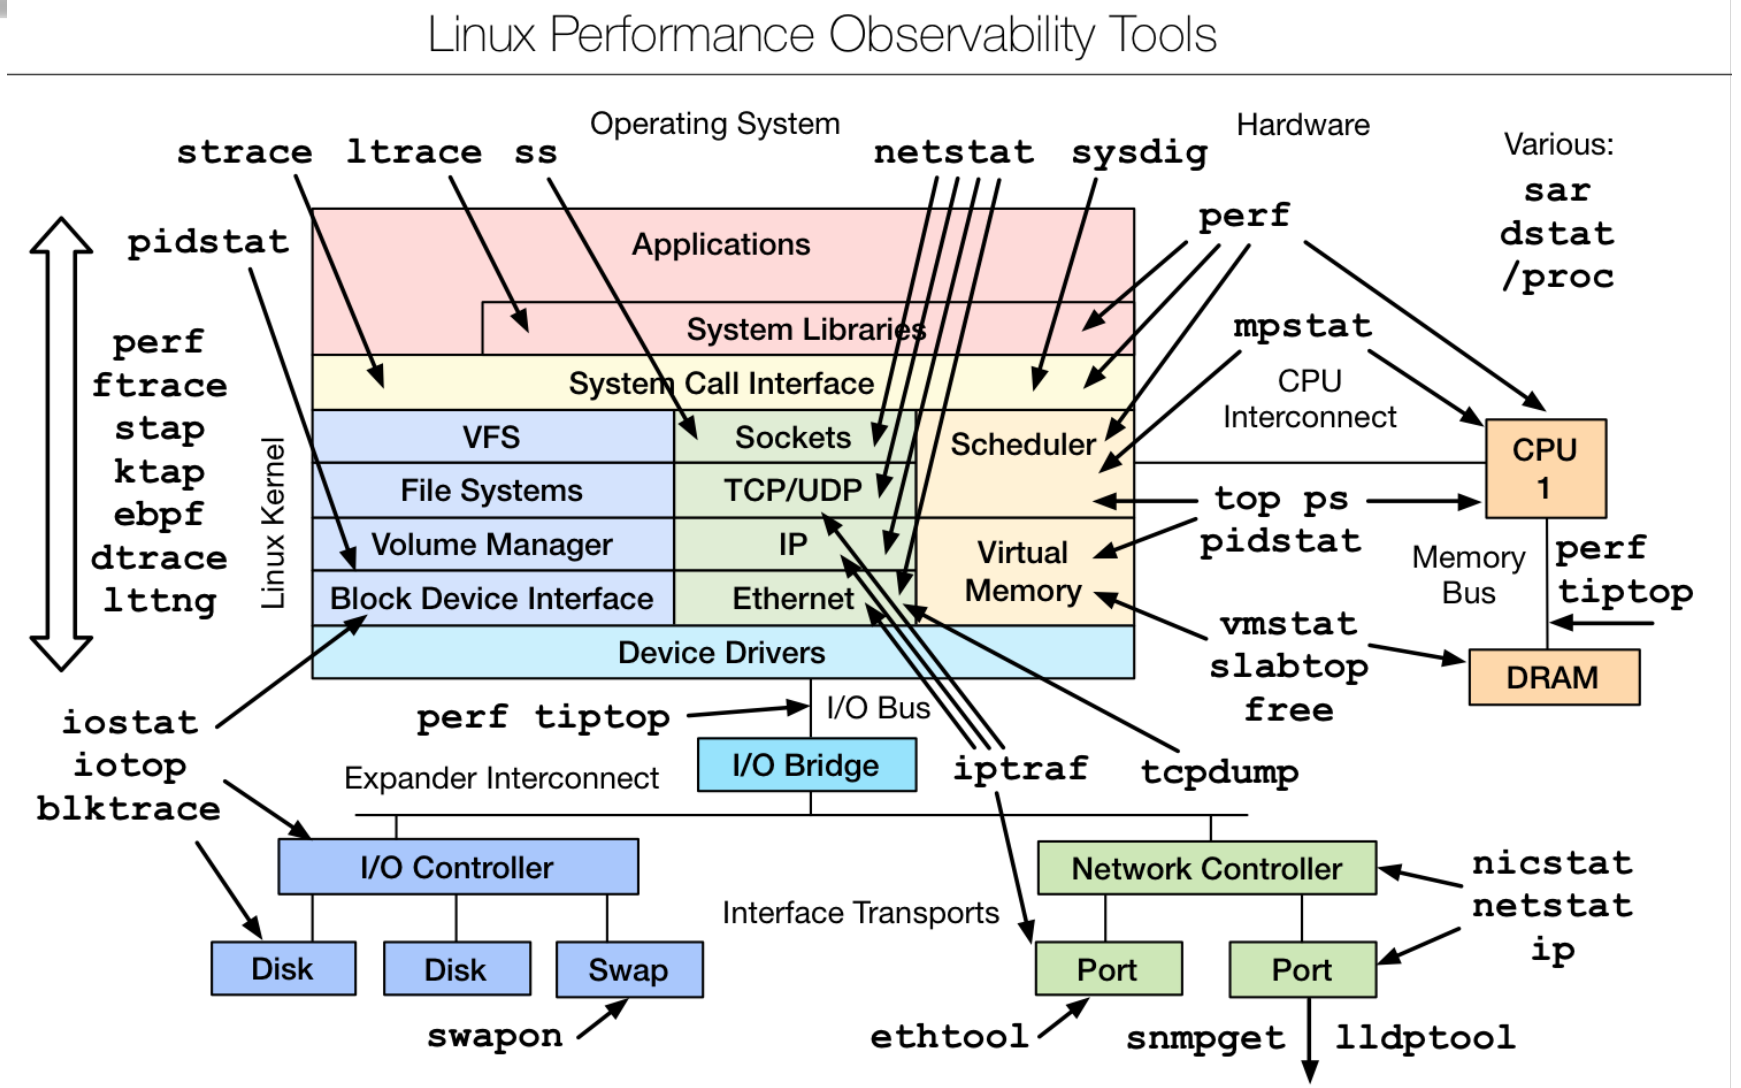

Brendan Gregg : www.brendangregg.com